EJERCICIOS DE HADOOP

NOMBRE ALUMNO: TANIA BATISTA

Devolver el resultado de ejecutar el siguiente comando (1 punto)
 \$HADOOP_HOME/bin/hdfs dfs -cat /outHDFS/*

RESPUESTA:



- 2. ¿Cuál de los siguientes funcionalidades pertenecen a un NameNode de HDFS? (1 punto)
- a. Transferir bloques de datos de los datanodes a los clientes
- b. Mantener el árbol del sistema de archivos y los metadatos de todos los ficheros y directorios
- c. Controlar los procesos de Map Reduce
- d. Almacenar bloques de datos
- e. Ninguna de las opciones es correcta

RESPUESTA:

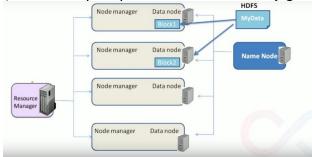
- b. Mantener el árbol del sistema de archivos y los metadatos de todos los ficheros y directorios
- 3. ¿Cuál de los siguientes funcionalidades pertenece a un DataNode de HDFS? (1 punto)
- a. Mantener el árbol del sistema de archivos y los metadatos de todos los ficheros y directorios.
- b. Controlar la ejecución de una tarea de mapeo o de reduce individual.
- c. Gestionar el sistema de espacios de nombres de los archivos.
- d. Almacenar y recuperar bloques cuando los clientes o el NameNode lo solicita.
- e. Ninguna de las opciones es correcta.

RESPUESTA:

- d. Almacenar y recuperar bloques cuando los clientes o el NameNode lo solicita.
- 4. ¿Cuál de las siguientes frases es cierta con respecto a YARN? (1 punto)
- a. Implementa un gestor de ficheros para todos los frameworks de Hadoop.
- b. Permitir acceso a los datos de HDFS a programas que no estén desarrollados en Hadoop.
- c. Permitir a múltiples Namenodes con sus propios namespaces, compartir el pool de Datanodes.
- d. Usar el JournalNode para decidir el NameNode activo.
- e. Ninguna de las anteriores es correcta.

RESPUESTA:

a. Implementa un gestor de ficheros para todos los frameworks de Hadoop. (Framework para planificación de tareas y gestión de recursos del cluster)



- 5. HDFS está diseñado para (1 punto)
- a. Ficheros grandes, acceso continuo a los datos y hardware de grandes prestaciones.
- b. Ficheros pequeños, acceso continuo a los datos y hardware básico.
- c. Ficheros grandes, baja latencia de acceso y hardware básico.
- d. Ficheros grandes, acceso continuo a los datos y hardware básico.
- e. Ninguna de las anteriores es correcta.

RESPUESTA:

d. Ficheros grandes, acceso continuo a los datos y hardware básico. (Pero el hardware no debe ser tan basico - veo que Hadoop está diseñado para "industry standard hardware")

- 6. ¿En cuál de los siguientes escenarios usarías Hadoop? (1 punto)
- a. Analizar los signos vitales de un bebé en tiempo real.
- b. Obtener las tendencias de acciones bursátiles cada minuto.
- c. Procesar un sensor meteorológico para predecir la trayectoria de un huracán.
- d. Procesar billones de mensajes de email para ejecutar análisis de texto.
- e. Ninguna de las anteriores.

RESPUESTA:

d. Procesar billones de mensajes de email para ejecutar análisis de texto.

(Hadoop va demasiado lento para A y B. Pero quizás se podría usar para C, porque Hadoop es capaz de procesar datos de varios tipos, como quizas los datos de un arduino conectado a sensores meterológicos. El único problema sería que Hadoop no es bueno para la analítica, ni para acceso random o interactivo. Entonces los datos meterológicos o los mensajes de email deben ser *analisados* con otro data warehouse.)

- 7. ¿Cuál de las siguientes frases es cierta? (1 punto)
- a. Hadoop es una nueva tecnología diseñada para reemplazar las bases de datos relacionales.
- b. Hadoop incluye componentes open source y closed source.

- c. Hadoop se puede usar para bigdata, DSS y OLTP.
- d. Todas las anteriores son correctas.
- e. Ninguna de las anteriores es correcta.

RESPUESTA:

e. Ninguna de las anteriores es correcta.

Explicación:

- a. Hadoop NO puede remplazar las bases de datos relacionales. (Tienen funciones diferentes).
- b. Hadoop incluye componentes open source, pero los componentes "closed source" solo se encuentran con la distribuión M5 de MapR. Las otras distribuciones de Hadoop son open source.
- c. Hadoop se puede usar para bigdata y DSS, PERO NO para OLTP. "Hadoop doesn't provide any random access to the data stored in it's file. So we can't use Hadoop as an OLTP database which is characterized by INSERT UPDATE DELETE."
- d. Todas las anteriores son correctas

8. Describe con tus palabras (no usar wikipedia ni información por internet) el funcionamiento de los distintos demonios de HDFS (3 puntos) RESPUESTA: (Mi explicación es en inglés, porque todavía no conozco muy bien el vocabulario técnico en español.)

Hadoop has 5 daemons, which always run in the background: NameNode, Secondary NameNode, DataNode, JobTeacker and TaskTracker. HDFS uses only the first 3.

NameNode: Master node, and directory tree of HDFS. Does not store copies of actual data, instead it just tracks where everything goes. As the highest node in the hierarchy, it a single point of failure - so it needs to be running all the time for the clusters to be found.

Secondary NameNode: It's like a backup node in case the NameNode fails, so that the clusters can still be found. It is not an exact copy of NameNode, because it merges the edits while creating checkpoints. It stores the directory image on a separate machine.

DataNode: this is the node that contains the actual data. It has replicates of the data so that files can be accessed in parallel. (For example, by the MapReduce TaskTrackers)

EJERCICIOS DE HDFS

A. WORD COUNT

Partiendo de las letras de las siguientes canciones

- 1. Crear ficheros de texto en la máquina ubuntu
- 2. Subir los ficheros a HDFS
- 3. Ejecutar un word count y resolver las preguntas del formulario.
 - A. Acceder al jobhistory e indicar los valores de "Status" y "Map Total" del job con el nombre "word count"
 - B. Palabra que se repite más veces
 - C. Palabra que se repite 6 veces
 - D. Cuántas veces aparece la palabra eyes

RESPUESTA 1. Crear ficheros de texto en la máquina ubuntu

Create 3 new files. For each file, copy the song text and paste it, using the nano command to open the text editor.

nano /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song1.txt

nano /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song2.txt

bigdata@bigdata:~/hadoop\$ nano /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song2.txt

Archivo: /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song2.txt

PINK FLOYD "Pigs (Three Different Ones)" Big man, pig man, ha ha, charade you are

nano /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song3.txt

bigdata@bigdata:~/hadoop\$ nano /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song3.txt

Archivo: /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in/song3.txt

```
DAVE MATTHEWS BAND "Pig"
Isn't it strange
How we move our lives for another day
```

RESPUESTA 2. Subir los ficheros a HDFS

Create the directory, carpetaWordCount. (previously done during exercises)

\$ hdfs dfs -mkdir /user/bigdata/carpetaWordCount

bigdata@bigdata:~/hadoop\$ hdfs dfs -mkdir /user/bigdata/carpetaWordCount

Upload the text files to the word counter directory

\$ hdfs dfs -copyFromLocal /home/bigdata/ejemplos/Hadoop/MapReduce/wc-in /user/bigdata/carpetaWordCount
bigdata@bigdata:~/hadoop\$ hdfs dfs -copyFromLocal /home/bigdata/ejemplos/Hadoop/MapReduce
/wc-in /user/bigdata/carpetaWordCount

RESPUESTA 3. Ejecutar un word count y resolver las preguntas del formulario.

Execute a word count:

hadoop jar \$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar wordcount/user/bigdata/carpetaWordCount/wc-in//user/bigdata/carpetaWordCount/wc-out

bigdata@bigdata:~/hadoop\$ hadoop jar \$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce
-examples-2.9.0.jar wordcount /user/bigdata/carpetaWordCount/wc-in/ /user/bigdata/carpet
aWordCount/wc-out

..wait for it to apply mapreduce

```
18/02/21 16:10:50 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
18/02/21 16:10:51 INFO input.FileInputFormat: Total input files to process : 5
18/02/21 16:10:51 INFO mapreduce.JobSubmitter: number of splits:5
18/02/21 16:10:51 INFO Configuration.deprecation: yarn.resourcemanager.system-metrics-pub
lisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
```

Job Counters Killed map tasks=1 Launched map tasks=5 Launched reduce tasks=1 Data-local map tasks=5 Total time spent by all maps in occupied slots (ms)=103024 Total time spent by all reduces in occupied slots (ms)=4803
Total time spent by all map tasks (ms)=103024
Total time spent by all reduce tasks (ms)=4803 Total vcore-milliséconds taken by all map tasks=103024 Total vcore-milliseconds taken by all reduce tasks=4803 Total megabyte-milliseconds taken by all map tasks=105496576 Total megabyte-milliseconds taken by all reduce tasks=4918272 Map-Reduce Framework Map input records=140 Map output records=870 Map output bytes=7769 Map output materialized bytes=4912 Input split bytes=666 Combine input records=870 Combine output records=426 Reduce input groups=369 Reduce shuffle bytes=4912 Reduce input records=426 Reduce output records=369 Spilled Records=852 Shuffled Maps =5 Failed Shuffles=0 Merged Map outputs=5 GC time elapsed (ms)=1837 CPU time spent (ms)=3020 Physical memory (bytes) snapshot=1387282432 Virtual memory (bytes) snapshot=13658439680 Total committed heap usage (bytes)=901644288 Shuffle Errors BAD ID=0 CONNECTION=0 IO_ERROR=0 WRONG_LENGTH=0 WRONG MAP=0 WRONG_REDUCE=0 File Input Format Counters Bytes Read=4293 File Output Format Counters Bytes Written=2837

hdfs dfs -cat /user/bigdata/carpetaWordCount/wc-out/*

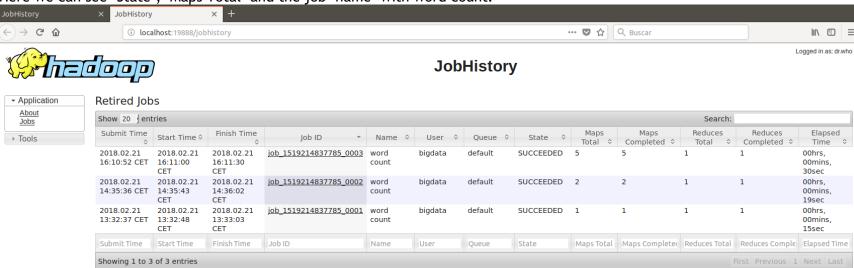
```
bigdata@bigdata:~/hadoop$ hdfs dfs -cat /user/bigdata/carpetaWordCount/wc-out/*
"March 1
'Pig"
        1
'Pias
keep
Three 1
no
         1
 . . . . ! . . . . . ! . . . . . ! . . . . . !
                                     1
411
         1
Almost
And
BAND
         1
         1
Big
```

A. Acceder al jobhistory e indicar los valores de "Status" y "Map Total" del job con el nombre "word count"

Check that everything is running correctly:

bigdata@bigdata:~/hadoop\$ jps 22497 SecondaryNameNode 18084 ResourceManager 18230 NodeManager 22102 NameNode 22281 DataNode 16811 JobHistoryServer 25148 Jps

To see details about jobs in MapReduce that have been executed, we go to http://localhost:19888/jobhistory Here we can see "State", "Maps Total" and the job "name" with word count.



Use the -cat file function to create a new file named "songs" hdfs dfs -cat /user/bigdata/carpetaWordCount/wc-out/* > songs.txt

bigdata@bigdata:~/hadoop\$ hdfs dfs -cat /user/bigdata/carpetaWordCount/wc-out/* > songs.txt

B. Palabra que se repite más veces:

```
Apply "sort", one of the programs suggested under hadoop-mapreduce-examples-2.9.0.jar n = return results in numerical order r = return results in descending order k 2 = which column we are applying this to
```

\$ cat songs.txt | sort -nrk 2

```
bigdata@bigdata:~/hadoop$ cat songs.txt | sort -nrk 2
the    33
it    24
a    22
your    18
to    15
of    15
```

Respuesta: THE aparece 33 veces

C. Palabra que se repite 6 veces

```
Apply "grep", one of the programs suggested under hadoop-mapreduce-examples-2.9.0.jar

grep: A map/reduce program that counts the matches of a regex in the input.

bigdata@bigdata:~/hadoop$ grep --help
Uso: grep [OPCIÓN]... PATRÓN [ARCHIVO]...
Search for PATTERN in each FILE.
Example: grep -i 'hello world' menu.h main.c
```

grep 6 songs.txt

```
bigdata@bigdata:~/hadoop$ grep 6 songs.txt
You 6
charade 6
ha 6
ha, 6
laugh 6
our 6
we 6
```

It looks like "ha" and "you" appear more than 6 times, under different punctuation and capitalization.

```
bigdata@bigdata:~/hadoop$ grep "you" songs.txt
you 14
you're 10
your 18
```

Respuesta: charade, laugh, our, we

D. Cuántas veces aparece la palabra eyes

```
grep "eyes" songs.txt
bigdata@bigdata:~/hadoop$ grep "eyes" songs.txt
eyes 3
eyes, 1
```

Respuesta: 4

B. SUDOKU

4. Ejecutar el programa sudoku con los siguientes parámetros:

- Programa: sudoku

sudoku: A sudoku solver.

\$ sudo apt install sudoku

```
bigdata@bigdata:~/hadoop$ sudo apt install sudoku
[sudo] password for bigdata:
Leyendo lista de paquetes... Hecho
Creando árbol de dependencias
Leyendo la información de estado... Hecho
Se instalarán los siguientes paquetes NUEVOS:
    sudoku
```

- Path fichero

En la ruta del fichero habrá que indicar la ruta en la que se encuentre un fichero que tendrá la siguiente información:

? 463??825 ?????24?? 82??6??7? 7??4????2 38????6?9 ?6?28???? ?7???5?3? 538??7???

\$ nano sudoku.txt

bigdata@bigdata:~/hadoop\$ nano sudoku.txt

```
GNU nano 2.8.6

Archivo: sudoku.txt

Archivo: sudoku.txt

Archivo: sudoku.txt

Archivo: sudoku.txt

Archivo: sudoku.txt

Archivo: sudoku.txt

Archivo: sudoku.txt
```

Indicar todos los resultados del sudoku de ejemplo

Take the wordcount command, and change it to sudoku:

\$ hadoop jar \$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar wordcount /user/bigdata/carpetaWordCount/wc-out

```
$ hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar sudoku /home/bigdata/hadoop/sudoku.txt
bigdata@bigdata:~/hadoop$ hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar su
Solving /home/bigdata/hadoop/sudoku.txt
1 4 6 3 7 9 8 2 5
9 5 7 8 1 2 4 6 3
8 2 3 5 6 4 9 7 1
7 1 5 4 9 6 3 8 2
3 8 2 7 5 1 6 4 9
4 6 9 2 8 3 5 1 7
6 7 1 9 4 5 2 3 8
5 3 8 6 2 7 1 9 4
2 9 4 1 3 8 7 5 6
```

C. PI

- 5. Ejecutar el programa "pi" con los siguientes parámetros de entrada e indicar el valor devuelto.
- Programa: pi
- N° de mapeos: 2

- N° de muestras por mapeo: 4

\$ sudo apt install pi

```
bigdata@bigdata:~/hadoop$ sudo apt install pi
Leyendo lista de paquetes... Hecho
Creando árbol de dependencias
Levendo la información de estado... Hecho
Se instalarán los siguientes paquetes adicionales:
 libcln6
Se instalarán los siguientes paquetes NUEVOS:
  libcln6 pi
O actualizados, 2 nuevos se instalarán, O para eliminar y 142 no actualizados.
Se necesita descargar 467 kB de archivos.
Se utilizarán 1.533 kB de espacio de disco adicional después de esta operación.
;Desea continuar? [S/n] S
Des:1 http://es.archive.ubuntu.com/ubuntu artful/universe amd64 libcln6 amd64 1.3.4-2 [460 kB]
Des:2 http://es.archive.ubuntu.com/ubuntu artful/universe amd64 pi amd64 1.3.4-2 [6.068 B]
Descargados 467 kB en 0s (850 kB/s)
Seleccionando el paquete libcln6 previamente no seleccionado.
(Leyendo la base de datos ... 172152 ficheros o directorios instalados actualmente.)
Preparando para desempaquetar .../libcln6 1.3.4-2 amd64.deb ...
Desempaquetando libcln6 (1.3.4-2) ...
Seleccionando el paquete pi previamente no seleccionado.
Preparando para desempaquetar .../archives/pi 1.3.4-2 amd64.deb ...
Desempaquetando pi (1.3.4-2) ...
Configurando libcln6 (1.3.4-2) ...
Configurando pi (1.3.4-2) ...
Procesando disparadores para libc-bin (2.26-0ubuntu2.1) ...
Procesando disparadores para man-db (2.7.6.1-2) ...
```

\$ pi --help

```
bigdata@bigdata:~/hadoop$ pi --help
Usage: pi [digits]
Compute decimal Archimedes' constant Pi to arbitrary accuracy.
```

Take the wordcount command, and change it to pi:

\$ hadoop jar \$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar wordcount /user/bigdata/carpetaWordCount/wc-out

\$ hadoop jar \$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar pi 2 4

```
gdata:~/hadoop$ hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar pi 2 4
         rguatagotguata.-/maudu
umber of Maps = 2
amples per Map = 4
rote input for Map #0
rote input for Map #1
Worke input for Map #1
Starting Job
18/02/21 17:50-45 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
18/02/21 17:50-45 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
18/02/21 17:50-45 INFO input FileInputFormat: Total input files to process : 2
18/02/21 17:50-46 INFO input FileInputFormat: Total input files to process : 2
18/02/21 17:50-47 INFO configuration deprecation: yearn resourcemanager.system-netrics-publisher.enabled is deprecated.
18/02/21 17:50-47 INFO infiguration deprecation: yearn resourcemanager.system-netrics-publisher.enabled is deprecated.
18/02/21 17:50-47 INFO input yearneting. Submitted application application_15:19214837785_0004
18/02/21 17:50-48 INFO mapreduce.Job: Inmuning job: job.1510214837785_0004
18/02/21 17:50-56 INFO mapreduce.Job: ununing job: job.1510214837785_0004 running in uber mode : false
18/02/21 17:50-56 INFO mapreduce.Job: map 0% reduce 0%
18/02/21 17:51:06 INFO mapreduce.Job: map 100% reduce 0%
18/02/21 17:51:10 INFO mapreduce.Job: map 100% reduce 100%
18/02/21 17:51:11 INFO mapreduce.Job: Job job.1510214837785_0004 completed successfully
18/02/21 17:51:12 INFO mapreduce.Job: Sub job.519214837785_0004 completed successfully
File System Counters
                                    21 17:51:12 INFO mapreduce.Job: Counters: 49
FILE System Counters
FILE: Number of bytes written=606414
FILE: Number of bytes written=606414
FILE: Number of large read operations=0
FILE: Number of large read operations=0
HDFS: Number of bytes read=5345
HDFS: Number of bytes read=5345
HDFS: Number of read operations=11
HDFS: Number of read operations=11
HDFS: Number of read operations=0
HDFS: Number of large read operations=0
Launched map tasks=2
Launched reduce tasks=1
                                                                                Launched map tasks=2
Launched reduce tasks=1
Data-local map tasks=2
Total time spent by all maps in occupied slots (ms)=15445
Total time spent by all reduces in occupied slots (ms)=3759
Total time spent by all map tasks (ms)=15445
Total time spent by all reduce tasks (ms)=3759
Total voor=-milliseconds taken by all map tasks=15445
Total voor=-milliseconds taken by all reduce tasks=3759
Total voors-milliseconds taken by all reduce tasks=3759
Total voors-milliseconds taken by all reduce tasks=3759
                                                                                          Total megabyte-milliseconds taken by all map tasks=15815680
Total megabyte-milliseconds taken by all reduce tasks=3849216
                                        Total megabyte-milliseconds taken
Map-Reduce Framework
Map input records=2
Map output records=3
Map output bytes=36
Map output Materialized bytes=56
Input split bytes=298
Combine input records=0
Combine output records=0
Reduce input groups=2
Reduce shuffle bytes=56
Reduce input records=4
Reduce output records=4
Reduce output records=0
                                                                                     Reduce input records=4
Reduce output records=8
Spilled Records=8
Shuffled Maps =2
Falled Shuffles=0
Merged Map outputs=2
CC time elapsed (ns)=378
CPU time spent (ns)=1400
Physical memory (bytes) snapshot=663072768
Virtual memory (bytes) snapshot=6832381952
Total committed heap usage (bytes)=408158208
e Errors
                                            Shuffle Errors
BAD_ID=0
                                                                                           CONNECTION=0
                                                                                           IO_ERROR=0
                                                                                           WRONG_LENGTH=0
WRONG_MAP=0
                                            WRONG_REDUCE=0
File Input Format Counters
Bytes Read=236
    File Output Format Counters
Bytes Written=97
Job Finished in 27.925 seconds
Estimated value of Pi is 3.50000000
```

<u>C. P</u>

6. Ejecutar el programa "pi" con los siguientes parámetros de entrada e indicar el valor devuelto.

- Programa: pi
- N° de mapeos: 5
- N° de muestras por mapeo: 10

```
hadoop jar $HADOOP HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar pi 5 10
bigdata@bigdata:~/hadoop$ hadoop jar $HADOOP HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.9.0.jar
Number of Maps = 5
 Samples per Map = 10
 Wrote input for Map #0
 Wrote input for Map #1
 Wrote input for Map #2
 Wrote input for Map #3
Wrote input for Map #4
             Map output records=10
Map output bytes=90
Map output bytes=91
Map output materialized bytes=140
Input split bytes=745
Combine input records=0
              Combine output records=0
Reduce input groups=2
Reduce shuffle bytes=140
              Reduce input records=10
Reduce output records=0
               Spilled Records=20
              Merged Map outputs=5
GC time elapsed (ms)=1996
             CPU time spent (ms)=2590
Physical memory (bytes) snapshot=1328648192
Virtual memory (bytes) snapshot=13658439680
Total committed heap usage (bytes)=901644288
       Shuffle Errors
BAD ID=0
              CONNECTION=0
IO_ERROR=0
              WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
       File Input Format Counters
Bytes Read=590
       File Output Format Counters
Bytes Written=97
```

EJERCICIOS DE MAP REDUCE

1. Escribe las traducciones de la palabra PIG.

I followed the steps from your MapReduce example (WordCount) as well as the 8 steps for this exercise. ("Ejercicio diccionario 1/3")

Crear nuestro fichero Dictionary.java

Partiendo de los siguientes pantallazos o del documento de ejemplo, crear un fichero llamado <u>Dictionary.java</u>

Ensure that all the services are running properly **start-dfs.sh**

start-yarn.sh

jps

```
bigdata@bigdata:~/hadoop$ jps
22497 SecondaryNameNode
18084 ResourceManager
2309 Jps
18230 NodeManager
22102 NameNode
22281 DataNode
16811 JobHistoryServer
```

Create a Dictionay.java file

cd /home/bigdata/ejemplos/Hadoop/MapReduce

mkdir ejemploDictionary

cd ejemploDictionary

sudo nano Dictionary.java

```
bigdata@bigdata:~/hadoop$ cd /home/bigdata/ejemplos/Hadoop/MapReduce
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce$ mkdir ejemploDictionary
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce$ cd ejemploDictionary
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary$ sudo nano Dictionary.java
[sudo] password for bigdata:
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary$
```

Compilar el fichero

Al compilarlo, os aparecerá un mensaje de un método deprecated. Revisar el código y rectificarlo para compilarlo correctamente.

Copy and paste the text from the Dictionary.java.docx file

```
GNU nano 2.8.6
                                      Archivo: Dictionary.java
mport java.io.IOException;
mport java.util.StringTokenizer;
mport org.apache.hadoop.conf.Configuration;
mport org.apache.hadoop.fs.Path;
mport org.apache.hadoop.io.IntWritable;
mport org.apache.hadoop.io.Text;
mport org.apache.hadoop.mapreduce.Job;
mport org.apache.hadoop.mapreduce.Mapper;
mport org.apache.hadoop.mapreduce.Reducer;
mport org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
mport org.apache.hadoop.mapreduce.lib.input.KeyValueTextInputFormat;
mport org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
public class Dictionary {
oublic static class WordMapper
        extends Mapper<Text, Text, Text, Text>{
 private Text word = new Text();
 public void map(Text key, Text value, Context context
                        ) throws IOException, InterruptedException {
   StringTokenizer itr = new StringTokenizer(value.toString(),",");
         (itr.hasMoreTokens()) {
        word.set(itr.nextToken());
        context.write(key,word);
```

Crear el .jar

Inside the ejemploDictionary file, create a dictionary.jar file with the classes

javac -classpath \$HADOOP_HOME/share/hadoop/common/hadoop-common-2.9.0.jar:\$HADOOP_HOME/share/hadoop/common/lib/hadoop-annotations-2.9.0.jar:\$HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-client-core-2.9.0.jar Dictionary.java jar cf /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary.jar Dictionary.class

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary\$ javac -classpath \$\text{SHADOOP_HOME/share/hadoop/common/hadoop-common-2.9.0.jar:\$\text{SHADOOP_HOME/share/hadoop} / \text{Nib/hadoop-annotations-2.9.0.jar:\$\text{SHADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-client-core-2.9.0.jar Dictionary.java bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary.jar Dictionary.class

Check that we do indeed have dictionary jar and its components inside the directory.

Is /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary\$ ls /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary
Dictionary\$AllTranslationsReducer.class Dictionary.class dictionary.jar Dictionary.java Dictionary\$WordMapper.class

Read the permissions for dictionary.jar

Is -Irt /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary.jar

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary\$ ls -lrt /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary.jar
-rw-r--r-- 1 bigdata bigdata 1276 feb 22 00:12 /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary.jar

Descargar el fichero

Lo primero que haremos es descargarnos los diferentes diccionarios a una nueva carpeta (Emplear por ejemplo comando wget)

wget http://www.ilovelanguages.com/IDP/files/Spanish.txt

wget http://www.ilovelanguages.com/IDP/files/Italian.txt

wget http://www.ilovelanguages.com/IDP/files/French.txt

wget http://www.ilovelanguages.com/IDP/files/German.txt

Download all 4 of the dictionaries by pasting the code links:

Create a new directory, dictionary-in-local, where the text file will go

mkdir /home/biqdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local/

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary\$ mkdir /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local/

Check that we have the HDFS folder called dictionary-in-local

```
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary$ ls
Dictionary$AllTranslationsReducer.class dictionary-in-local Dictionary.java French.txt Italian.txt
Dictionary.class dictionary.jar Dictionary$WordMapper.class German.txt Spanish.txt
```

Merge de ficheros

Como Hadoop trabaja mejor con ficheros grandes, haremos un merge de los 4 ficheros para obtener un único fichero diccionario. Por ejemplo se puede emplear el comando CAT redirigiendo la salida a un nuevo fichero llamado dictionary.txt

Put the 4 text files inside of 1 text file called dictionary.txt. (Then put that inside the directory dictionary-in-local) cat Spanish.txt Italian.txt French.txt German.txt > dictionary.txt

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary\$ cat Spanish.txt Italian.txt French.txt German.txt > dictionary.txt
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary\$ mv dictionary.txt dictionary-in-local

Check that the file contains the 4 sets of keys and values

```
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary$ cd dictionary-in-local
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local$ ls
dictionary.txt
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local$ nano dictionary.txt
```

Here you can see the end of the English-Spanish dictionary, and the beginning of the English-Italian

```
zoologist
                el zoo/logo[Noun]
zoology la zoologi/a[Noun]
       pasar zumbando[Verb]
zounds ca/spita
zucchini
                el calabaci/n[Noun]
        un, uno, una[Article]
        uno, una, un
        un,uno,una,un'[Article]
aardvark
                oritteropo
aardvarks
                oritteropi
        da[Preposition]
aback
        di dietro
aback essere sorpreso/essere preso alla sprovvista
abacterial
                abatterico
abacus abaco
abacuses
                abachi[Noun]
abacuses
                abaci
```

Get rid of the previous language texts

rm Spanish.txt Italian.txt German.txt French.txt

```
bigdata@bigdata:-/ejemplos/Hadoop/MapReduce/ejemploDictionary$ rm Spanish.txt Italian.txt German.txt French.txt
bigdata@bigdata:-/ejemplos/Hadoop/MapReduce/ejemploDictionary$ ls
Dictionary$AllTranslationsReducer.class Dictionary.class dictionary-in-local dictionary.jar Dictionary.java Dictionary$WordMapper.class -in-local
bigdata@bigdata:-/ejemplos/Hadoop/MapReduce/ejemploDictionary$
```

Subir el fichero a HDFS

Empleando alguno de los comandos de subida a HDFS mover el fichero a una nueva carpeta en la ruta /user/bigdata/mapreduce poniéndole el nombre diccionario.txt.

We need dictionary-in-local inside HDFS, so create a folder in user/bigdata. Load the files into this HDFS folder.

hdfs dfs -put /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local/* /user/bigdata/dictionary-with-javabtgdataabtgdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary-in-locals hdfs dfs -put /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary-in-local/i

Confirm that it loaded into /user/bigdata correctly

hdfs dfs -ls /user/biadata/dictionary-with-java

```
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local$ hdfs dfs -ls /user/bigdata/dictionary-with-java
-rw-r--r- 1 bigdata supergroup 598677 2018-02-22 12:10 /user/bigdata/dictionary-with-java
```

Create an output folder, dictionary-java-output, where all the jar-executed results will be outputed to:

hadoop jar /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary.jar Dictionary dictionary-with-java dictionary-java-output

```
gdata:-/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local$ hadoop jar /home/bigdata/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary.jar Dictiona
  dictionary-with-java dictionary-java-output
18/02/22 12:18:47 INFO client.RMProxy: Connecting to ResourceManager at /0.0.0.0:8032
18/02/22 12:18:48 WARN mapreduce.JobResourceUploader: Hadoop command-line option parsing not performed. Implement the Tool interface and execute your application with ToolRunn
18/02/22 12:18:48 INFO input.FileInputFormat: Total input files to process : 1
18/02/22 12:18:48 INFO mapreduce.JobSubmitter: number of splits:1
18/02/22 12:18:48 INFO Configuration.deprecation: yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
18/02/22 12:18:49 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1519214837785_0008
18/02/22 12:18:49 INFO impl.YarnClientImpl: Submitted application application 1519214837785 0008
18/02/22 12:18:49 INFO mapreduce.Job: The url to track the job: http://bigdata:8088/proxy/application_1519214837785_0008/
18/02/22 12:18:49 INFO mapreduce.Job: Running job: job_1519214837785_0008
18/02/22 12:19:00 INFO mapreduce.Job: Job job_1519214837785_0008 running in uber mode : false
18/02/22 12:19:00 INFO mapreduce.Job: map 0% reduce 0%
18/02/22 12:19:08 INFO mapreduce.Job: map 100% reduce 0%
18/02/22 12:19:15 INFO mapreduce.Job: map 100% reduce 100%
18/02/22 12:19:17 INFO mapreduce.Job: Job job_1519214837785_0008 completed successfully
```

Ejecutar el proceso map reduce.

En este ejemplo, como hemos visto no hay parámetros de entrada ya que vienen indicados en el código.

Confirm that the files are loaded.

hdfs dfs -ls /user/bigdata/*

```
bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local$ hdfs dfs -ls /user/bigdata/*
Found 2 items
                                            0 2018-02-21 16:06 /user/bigdata/carpetaWordCount/wc-in
drwxr-xr-x

    biqdata supergroup

             - bigdata supergroup
                                            0 2018-02-21 16:11 /user/bigdata/carpetaWordCount/wc-out
drwxr-xr-x
Found 1 items
                                            0 2018-02-22 01:19 /user/bigdata/dictionary-in-java/dictionary.txt
             1 bigdata supergroup
- CM- C-- C--
Found 2 items
             1 bigdata supergroup
                                            0 2018-02-22 12:19 /user/bigdata/dictionary-java-output/ SUCCESS
- FW- F-- F--
             1 bigdata supergroup
                                       525276 2018-02-22 12:19 /user/bigdata/dictionary-java-output/part-r-00000
                                       598677 2018-02-22 12:10 /user/biodata/dictionary-with-iava
```

hdfs dfs -cat /user/bigdata/dictionary-java-output/part-r-00000 > mapReducedDictionary.txt

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local\$ hdfs dfs -cat /user/bigdata/o

Devolver traducción de pig

grep pig mapReducedDictionary.txt

bigdata@bigdata:~/ejemplos/Hadoop/MapReduce/ejemploDictionary/dictionary-in-local\$ grep pig mapReducedDictionary

Resultado:

pig |cochon[Noun]|Schwein (n)|el chancho[Noun]|el puerco